

Pronóstico de la Demanda para Productos de Vida Útil Corta, en la categoría de líquidos, en una Empresa B2B de Derivados Lácteos

Andrés Cano, Andrés Meneses, Jhonattan Reales

andres.cano.consulting@gmail.com, a785496@hotmail.com, jhonatanreales21@gmail.com

Link repositorio: https://github.com/JhonattanReales21/innv_tec_1_icesi

Link presentación y video: [Proyecto de Innovacion Tecnologica I](#)

Resumen - Este trabajo aborda el reto de pronosticar la demanda de productos lácteos líquidos con vida útil corta en una empresa B2B. Dada la naturaleza perecedera del producto, se hace crítica la precisión en la predicción de la demanda para reducir pérdidas y mejorar la disponibilidad. Se aplicaron técnicas de series de tiempo, aprendizaje automático y algoritmos de regresión; clasificando la demanda según su variabilidad e intermitencia. Los modelos Holt-Winters, ARIMA, y algunos regresores fueron evaluados por SKU, eligiendo el de menor RMSE con diferentes protocolos de evaluación como ventana fija y ventana recursiva. Los resultados muestran que si es posible tener una asertividad mayor al 65% en el pronóstico semanal, teniendo un MAPE de 7% para la ponderación de los mejores modelos por cada SKU.

Índice de Términos - Aprendizaje automático, demanda intermitente, Holt-Winters, Pronóstico de series de tiempo, Regresión, XGBoost, KNN, Elastic Net, Random Forest.

I. INTRODUCCION

La empresa objeto de estudio es una compañía B2B que comercializa productos lácteos, entre ellos una categoría crítica de productos líquidos con vida útil corta. Debido a la naturaleza perecedera de estos productos, la sincronización entre la producción, el despacho y la demanda real es esencial para evitar pérdidas por vencimiento o por falta de disponibilidad en los puntos de distribución.

Actualmente, la empresa enfrenta dificultades para predecir la demanda real de los productos líquidos, lo cual genera:

- Exceso de inventario y deterioro de producto.
- Faltantes en puntos de venta que derivan en venta perdida.
- Ineficiencia en la logística de abastecimiento y distribución.

En este proyecto nos planteamos desarrollar modelos de predicción de la demanda que permitan superar el 65% de asertividad semanal en la categoría de productos líquidos, utilizando técnicas de Machine Learning y series de tiempo en un horizonte de 6 meses.

El pronóstico de demanda para productos perecederos o de corta vida útil, especialmente en el sector de alimentos y bebidas, representa un reto logístico y analítico importante. Esto puede ser resultado de la alta variación, vida útil limitada y patrones de consumo irregulares a los que se ven expuestos esta clase de productos.

Tradicionalmente, se han aplicado modelos estadísticos como Medias móviles, ARIMA y SARIMA para realizar estimaciones sobre datos históricos. Estos modelos han demostrado resultados aceptables en entornos donde la estacionalidad y la estabilidad son muy marcadas. Sin embargo, su rendimiento y precisión disminuyen cuando la demanda se ve afectada por múltiples variables externas o cuando los comportamientos históricos no se reproducen de manera constante.

Dado lo anterior, se ha impulsado el uso de modelos más adaptables y robustos. Un ejemplo de esto lo llevaron a cabo en [1], con el desarrollo de Prophet, una herramienta de aprendizaje de máquinas que permite integrar eventos especiales y múltiples estacionalidades, resultando muy útil para productos cuya demanda se ve fuertemente influenciada por factores externos, tales como, días feriados, aspectos climáticos o ciclos de mercado, restricciones económicas, medidas políticas, entre otros. Prophet ha ganado popularidad en empresas que necesitan generar pronósticos precisos con bajo costo computacional y una interfaz accesible.

De manera similar, el aprendizaje automático ha cobrado relevancia en el contexto del pronóstico de demanda y/o la estimación de series temporales. Algoritmos como Random Forest, Gradient Boosting y XGBoost han sido implementados con éxito en cadenas de suministro de diversas industrias. En comparación con los algoritmos tradicionales, estos modelos se caracterizan por no asumir una estructura previa en los datos y son capaces de comprender relaciones no lineales complejas. En [2] determinaron que el modelo XGBoost lograba una mejora notable en la precisión de los pronósticos, después de incorporar al modelo variables como el número de puntos de venta, días hábiles, feriados y tendencias históricas de pedidos.

Casos reales como los de Danone, Nestlé y Unilever demuestran que integrar datos históricos, factores contextuales y modelos automatizados ha permitido mejorar y optimizar la distribución de productos lácteos y disminuir notablemente el desperdicio. Según [3], la adopción de modelos de machine learning en esta industria ha permitido alinear de mejor manera la producción con la demanda estimada, dando como resultado beneficios tanto económicos como ambientales.

Un ejemplo en América Latina es [4], en este estudio diseñaron un modelo de pronóstico para estimar la demanda semanal de productos alimenticios de alto consumo en un entorno real. Emplearon algoritmos de machine learning como XGBoost y Prophet, logrando mejorar de forma notable la precisión en comparación a los algoritmos tradicionales utilizados por la empresa del estudio. En este caso, los autores incorporaron variables como promociones, estacionalidades, feriados y patrones históricos de demanda.

Otro enfoque muy similar en el campo del aprendizaje de máquinas es el uso de redes neuronales recurrentes, en particular LSTM (Long Short-Term Memory). Estas redes están diseñadas para captar dependencias a largo plazo en series temporales, lo que resulta útil cuando existen rezagos o efectos acumulativos en el comportamiento del consumidor. En [5] aplicaron LSTM a productos alimenticios perecederos y obtuvieron mejoras en la precisión del pronóstico frente a otros modelos.

Además de los modelos en sí, la literatura enfatiza la importancia del preprocesamiento y la ingeniería de variables. La calidad del forecast no depende solo del algoritmo, sino de la riqueza y relevancia de las variables incluidas. Factores como si el día es feriado, si es fin de semana, el promedio de ventas históricas por punto de distribución, la cercanía al cierre de quincena, y la actividad escolar, son variables que pueden capturar patrones de comportamiento clave en la demanda.

En conclusión, los estudios revisados evidencian como un enfoque híbrido, combinando modelos estadísticos clásicos con técnicas modernas de aprendizaje automático, ofrece resultados significativos en la predicción de productos de vida útil corta. La clave del éxito reside en una integración efectiva entre los datos, las variables externas y la tecnología empleada.

II. MATERIALES Y MÉTODOS

El proyecto busca estimar la demanda para productos lácteos perecederos mediante modelos de series de tiempo y modelos de aprendizaje automático. Se desarrollan dos enfoques: univariado (modelos clásicos por SKU) y multivariado (regresores ML con variables explicativas y output multi-horizonte). Se parte de una clasificación de los productos con base en su variabilidad e intermitencia, lo cual orienta la selección de modelos adecuados. Para lograr esto se calcula el Coeficiente de Variación (CoV) y la Intermitencia (ADI) por SKU. Con estos se asigna una categoría de demanda: Smooth, Uneven, Irregular, Erratic o No Demand.

Para los productos en estudio el resultado obtenido para la categoría de demanda por sku es el siguiente:

<i>SKU</i>	<i>Clasificación de Demanda</i>
<i>SKU1</i>	Irregular
<i>SKU2</i>	Irregular
<i>SKU3</i>	Irregular
<i>SKU4</i>	Irregular

SKU5	Irregular
SKU6	Irregular
SKU7	Irregular
SKU8	Irregular
SKU9	Irregular
SKU10	Irregular
SKU11	Irregular
SKU12	Irregular
SKU13	Irregular
SKU14	Irregular
SKU15	Irregular
SKU16	Irregular
SKU17	Irregular
SKU18	Irregular
SKU19	Irregular
SKU20	Irregular
SKU21	Irregular
SKU22	Irregular
SKU23	Irregular
SKU24	Irregular
SKU25	Irregular
SKU26	Irregular

Tabla I

Con los resultados obtenidos anteriormente se puede ver con la siguiente tabla [8] que los mejores modelos para los SKU en estudio son ARIMA, Stepwise ARIMA, Holt-Winters, Double Exponential.

Clasificación	Modelos sugeridos (Model Set)	Notas clave
Smooth	Exponential Smoothing, Moving Average	Baja variabilidad, no hay tendencia marcada
Uneven	Holt-Winters (Additive o Multiplicative), ARIMA, Double Exponential	Variabilidad moderada, posibles patrones
Irregular	ARIMA, Stepwise ARIMA, Holt-Winters, Double Exponential	Tendencias leves, más ruido
Erratic	Croston's, Intermittent Demand Methods (TSB, SBA si se quiere extender), Moving Average	Demanda muy esporádica
No Demand	No se modela (forecast = 0 o revisión manual)	No aplica modelo estadístico

Tabla II

En este estudio vamos a abordar los modelos de ARIMA, Holt-Winters sugeridos por la literatura para casos en donde la tendencia es leve. Adicionalmente vamos a usar algoritmos de regresión como : XGBoost, Random Forest, Elastic Net y KNN.

Los datos usados como base para los modelos provienen de un archivo de excel, el cual fue recolectado por la empresa y contiene información diaria sobre los pedidos recibidos por cada día por SKU entre agosto 2024 a mayo 2025. Esta data pasó por procesos de limpieza y enriquecimiento de la información para poder ser usada en modelos de series de tiempo y modelos de regresión. Para las series de tiempo se aplicaron los siguientes ajustes:

- Corrección de Outliers (Se definen “upper y lower limit” como +/- dos veces la desviación estandar y se ajustan los valores atípicos al límite superior o inferior más cercano).
- Se rellenan valores incompletos de la serie con 0.
- Ajuste de tipo de dato para las fechas.

Para el enfoque haciendo uso de regresores, en adición a los ajustes anteriores, se agregaron las siguientes variables predictoras:

- Variables Temporales :
 - Día de la semana, día del mes, semana del mes
 - Flags binarios para: fin de semana, primeros 5 días del mes (por posible abastecimiento), quincena (± 2 días), vacaciones escolares (julio y diciembre).
- Lags y Promedios Móviles
 - 14 lags diarios hacia atrás, desde la semana anterior (Lag 7 a Lag 21).
 - 3 lags del mismo día de la semana (por ejemplo, los últimos 3 martes).
 - Promedios móviles, excluyendo los días de cero pedidos:
 - De los últimos 7 días.
 - Promedio semanal de la semana anterior (días -14 a -7).
 - Promedio de los mismos días de la semana en las 2 semanas anteriores.
 - Promedio de los mismos días de la semana en las 3 semanas anteriores.
- Descomposición STL
 - Para cada serie, se extraen los componentes de tendencia y estacionalidad.
 - Para cada componente se generan 14 lags desde la semana inmediatamente anterior (Lag_Tendencia_7 a Lag_Tendencia_21 y Lag_Estacionalidad_7 a 21).

Para hacer la validación de resultados de nuestros modelos utilizamos dos enfoques:

1. Ventana Fija : En este enfoque tomamos todos los datos disponibles y excluimos los últimos 7 días de conjunto de datos, los cuales los dejamos para validación. Con este tipo de ventana validamos modelos de AutoArima y Hotl-Winters.
2. Ventana recursiva : En este enfoque también excluimos los últimos 7 días de la serie adicionalmente, realizamos 3 cortes recursivos en la serie en donde en cada corte entrenamos con el histórico disponible y se predicen los siguientes 7 días.

Por la naturaleza del negocio y las limitaciones de los datos, se realizó un pronóstico diario de 7 días en el futuro para obtener un dato semanal que le sirviese a la planta de producción para realizar la programación de turnos, personal, maquinas, materiales de empaque, materias primas entre otros. Tanto un Forecast semanal como diario lo más preciso posible resulta importante para los programadores de piso como para la gerencia con el fin de evitar excesos o rupturas de inventario que puedan afectar el nivel de servicio principalmente con las tiendas de descuento (On Time in Full – OTIF).

A continuación, se presenta la relación de los modelos evaluados con las ventanas usadas para validación:

Modelo	Ventana Fija (últimos 7 días)	Ventana Recursiva (3 cortes)
AutoArima	Evaluado	
HoltWinters	Evaluado	Evaluado
ARIMA		Evaluado

XGBoost Regressor (Boosting)	Evaluado
Random Forest Regressor (Bagging)	Evaluado
Elastic Net (Modelo Lineal generalizado)	Evaluado
KNN Regressor (instance based model)	Evaluado

Tabla III

Todos los modelos evaluados pasaron por un proceso de optimización de hiperparametros :

Modelo	Funcion de optimizacion
AutoArima	No requiere, el modelo optimiza los parametros
HoltWinters	Optimizacion Bayesiana(Optuna)
ARIMA	Funcion propia Optimizacion parametros (p,d,q)
XGBoost Regressor (Boosting)	Optimizacion Bayesiana(Optuna)
Random Forest Regressor (Bagging)	Optimizacion Bayesiana(Optuna)
Elastic Net (Modelo Lineal generalizado)	Optimizacion Bayesiana(Optuna)
KNN Regressor (instance based model)	Optimizacion Bayesiana(Optuna)

Tabla IV

Para los modelos de ARIMA y Holtwinters con ventana se recursiva se aplicó la métrica del RMSE, en este caso se seleccionó un modelo por cada SKU y el modelo seleccionado fue el que tuvo mejor promedio de RMSE semanal durante las 3 semanas de corte.

Para el caso de AutoARIMA y Holtwinters con ventana fija se seleccionó el modelo con mejor RMSE en la última semana.

Para el caso de los regresores XGBRegressor, RandomForestRegressor, ElasticNet, KNeighborsRegressor la métrica utilizada para la selección del mejor modelo por SKU fue el SMAPE.

Finalmente obtuvimos resultados de diferentes combinaciones entre modelos y ventanas de evaluación con los mejores modelos de cada una de las combinaciones, entre estos resultados se seleccionó la métrica MAPE para la elección del mejor modelo por SKU, ya que esta métrica permite un entendimiento mayor por parte del negocio del significado de los resultados obtenidos.




Figura I

III. RESULTADOS

Los resultados obtenidos demuestran que el modelo Holt-Winters fue el más frecuente entre los seleccionados como mejor modelo por SKU, seguido por modelos de regresión como ElasticNet, XGBoost y KneighborsRegressor, dependiendo de la estructura de la serie y el método de validación aplicado.

- En promedio, se logró un **MAPE de 6.82%** al evaluar el modelo ganador por SKU, superando el objetivo planteado de asertividad semanal superior al 65%.
- La combinación de técnicas de **ventana fija**, **ventana recursiva** y **optimización bayesiana** permitió mejorar significativamente la capacidad predictiva.
- El **modelo Holt-Winters**, con distintas combinaciones de parámetros de suavizado y estacionalidad, fue el más dominante entre los SKUs con comportamiento irregular.
- Modelos como **ElasticNet** y **XGBoost** fueron seleccionados especialmente en aquellos SKUs donde se incorporaron variables externas mediante regresores multivariados.

La siguiente tabla resumen muestra los resultados de MAPE de cada tipo de validación alcanzada por SKU:

Producto	Regresores	Ventana Fija	Ventana Recursiva	Modelo Ganador
SKU1	7%	7%	12%	HW-add-add-a0.2-b0.2-g0.2
SKU10	20%	10%	20%	HW-None-add-a0.8-b0.2-g0.2
SKU11	6%	4%	12%	HW-add-add-a0.4-b0.6-g0.4
SKU12	17%	5%	28%	HW-add-add-a0.2-b0.4-g0.2
SKU13	20%	16%	19%	HW-None-add-a0.2-b0.2-g0.2
SKU14	10%	4%	19%	HW-add-None-a0.6-b0.8-g0.2
SKU15	2%	4%	20%	XGBRegressor
SKU16	27%	2%	4%	HW-None-add-a0.2-b0.2-g0.2
SKU17	1%	0%	27%	HW-add-add-a0.2-b0.6-g0.2
SKU18	9%	3%	6%	HW-None-None-a0.2-b0.2-g0.2
SKU19	14%	25%	69%	KneighborsRegressor
SKU2	5%	5%	11%	HW-None-add-a0.2-b0.2-g0.2
SKU20	7%	14%	154%	ElasticNet
SKU21	14%	11%	6%	HW-Trend(add)-seasonal(add)-a0.05-b0.07-g0.05

SKU22	3%	16%	9% ElasticNet
SKU23	1%	1%	2% HW-add-add-a0.6-b0.6-g0.2
SKU24	3%	5%	20% RandomForestRegressor
SKU25	2%	18%	4% ElasticNet
SKU26	11%	13%	14% ElasticNet
SKU3	2%	5%	9% ElasticNet
SKU4	7%	9%	22% ElasticNet
SKU5	6%	1%	5% HW-add-add-a0.2-b0.6-g0.2
SKU6	0%	3%	18% ElasticNet
SKU7	21%	15%	1% ARIMA(p0-d0-q1) se realiza evaluación de supuestos y los cumple.
SKU8	57%	42%	74% HW-add-add-a0.4-b0.8-g0.4
SKU9	34%	19%	56% HW-None-add-a0.8-b0.2-g0.2

Tabla V

Al juntar los mejores modelos según protocolo de evaluación y MAPE, encontramos que el error promedio esta cercano al 7% en todo el portafolio de líquidos (ver tabla)

SKU	Modelo Ganador	Method	Forecast	Pedidos	MAPE %
SKU1	HW-add-add-a0.2-b0.2-g0.2	MAPE ST Ventana Fija	150,488	140,520	7.09%
SKU10	HW-None-add-a0.8-b0.2-g0.2	MAPE ST Ventana Fija	8,244	9,180	10.20%
SKU11	HW-add-add-a0.4-b0.6-g0.4	MAPE ST Ventana Fija	7,457	7,200	3.57%
SKU12	HW-add-add-a0.2-b0.4-g0.2	MAPE ST Ventana Fija	3,699	3,900	5.15%
SKU13	HW-None-add-a0.2-b0.2-g0.2	MAPE ST Ventana Fija	3,293	3,900	15.55%
SKU14	HW-add-None-a0.6-b0.8-g0.2	MAPE ST Ventana Fija	15,144	15,840	4.39%
SKU15	XGBRegressor	MAPE Regresores	6,810	6,960	2.15%
SKU16	HW-None-add-a0.2-b0.2-g0.2	MAPE ST Ventana Fija	24,147	24,600	1.84%
SKU17	HW-add-add-a0.2-b0.6-g0.2	MAPE ST Ventana Fija	82,473	82,871	0.48%
SKU18	HW-None-None-a0.2-b0.2-g0.2	MAPE ST Ventana Fija	15,586	15,120	3.09%
SKU19	KneighnorsRegressor	MAPE Regresores	23,955	27,720	13.58%
SKU2	HW-None-add-a0.2-b0.2-g0.2	MAPE ST Ventana Fija	32,269	33,900	4.81%
SKU20	ElasticNet	MAPE Regresores	64,601	60,360	7.03%
SKU21	HW-Trend(add)-seasonal(add)-a0.05-b0.07-g0.05	MAPE ST Ventana Recursiva	28,900	30,600	5.56%
SKU22	ElasticNet	MAPE Regresores	24,230	25,080	3.39%
SKU23	HW-add-add-a0.6-b0.6-g0.2	MAPE ST Ventana Fija	33,808	33,600	0.62%
SKU24	RandomForestRegressor	MAPE Regresores	29,432	28,560	3.05%
SKU25	ElasticNet	MAPE Regresores	14,531	14,280	1.76%
SKU26	ElasticNet	MAPE Regresores	14,241	16,080	11.44%
SKU3	ElasticNet	MAPE Regresores	92,055	90,000	2.28%

SKU4	ElasticNet	MAPE Regresores	32,699	30,600	6.86%
SKU5	HW-add-add-a0.2-b0.6-g0.2	MAPE ST Ventana Fija	102,332	101,400	0.92%
SKU6	ElasticNet	MAPE Regresores	20,922	20,850	0.35%
SKU7	Arima (0,0,1)	MAPE ST Ventana Recursiva	69,333	70,200	1.24%
SKU8	HW-add-add-a0.4-b0.8-g0.4	MAPE ST Ventana Fija	8,586	14,760	41.83%
SKU9	HW-None-add-a0.8-b0.2-g0.2	MAPE ST Ventana Fija	5,970	7,380	19.10%
PROMEDIO DEL ERROR					6.82%

Tabla VI

Asumiendo un escenario de “underforecasting” donde el forecast es mucho menor que la demanda, se plantea el siguiente ejercicio como potencial impacto al proceso de todo el portafolio de líquidos en términos de ingresos por ventas:

Si de 154 de unidades en pedidos por semana, el forecast solo fue de 100 (Error 35% - Error Actual), estan en riesgo 54 unidades facturables. Considerando un precio de \$100 por SKU se estarían dejando de facturar \$5.400. Sin embargo, si se tiene un modelo con el 7% de error, es decir, 7 unidades en riesgo de facturación, se estarían dejando de facturar \$700. Al comparar \$5.400 del escenario actual vs \$700 con los pronósticos generados en este estudio, se puede observar que hay una reducción de la pérdida de ingresos por ventas de alrededor el 87%.

Por otro lado, en un escenario de “Overforecasting” donde el forecast supera la demanda se tiene la siguiente simulación: para un forecast de 100 unidades vs pedidos de 74 unidades (Error 35% - Error Actual) se tienen en potencial riesgo de producto fecha corta alrededor de 26 unidades que si se asume un costo de \$10 se podría estar hablando de una baja de \$260. Sin embargo, si se tiene un error del 7%, alrededor de 7 unidades en riesgo de esta por fuera de la política de recibo del cliente y por ende un riesgo de baja para la compañía se estaría habalndo de solo una potencial perdida de \$70. Lo anterior significa una reducción del 73% del riesgo de dar de baja inventario.

IV. DISCUSIÓN

Los hallazgos del proyecto confirman que la **clasificación previa de la demanda** (según su CoV y ADI) permitió asignar modelos apropiados según el tipo de serie, lo cual contribuyó a mejorar el rendimiento predictivo. La elección de modelos por SKU basados en su comportamiento “Irregular” (como se evidenció en todas las series) fue clave para definir estrategias de modelado.

- **Holt-Winters y ARIMA** demostraron ser adecuados para capturar estructuras de tendencia y estacionalidad moderada, cumpliendo con los supuestos estadísticos de manera razonable en la mayoría de los casos.
- **Modelos de regresión multivariados**, al incorporar variables temporales y de contexto, permitieron mejorar el pronóstico en series más complejas o con mayor ruido.
- El uso de **Optuna** para optimización bayesiana fue esencial para ajustar automáticamente los hiperparámetros, reduciendo tiempos de prueba y mejorando el desempeño general.
- Se identificó que algunos SKUs (por ejemplo, SKU8 y SKU9) presentaron valores atípicos en su MAPE debido a variaciones extremas o comportamiento errático, lo que sugiere oportunidades para incorporar modelos especializados para demanda intermitente (como Croston o TSB) en futuras etapas.

En términos operativos, se logró demostrar que **es viable predecir semanalmente la demanda de productos perecederos con un nivel de error aceptable**, lo que tiene un impacto directo sobre la eficiencia logística, reducción de desperdicios y disponibilidad de inventario.

V. CONCLUSIONES

El proyecto logró desarrollar un enfoque automatizado y adaptativo para el pronóstico de productos de vida útil corta. Superó el umbral de asertividad propuesto en varios SKUs y demostró la utilidad de modelos

segmentados por tipo de demanda. Se recomienda la integración de este pipeline en la operación semanal de la empresa y su expansión a otras categorías de producto.

- Se desarrolló e implementó un enfoque híbrido de pronóstico que combina modelos estadísticos clásicos y modelos de aprendizaje automático, ajustado a la naturaleza irregular de la demanda de productos líquidos perecederos.
- El sistema de clasificación de demanda y selección automatizada de modelos por SKU permitió alcanzar un **MAPE promedio de 6.82%**, superando el objetivo de negocio establecido.
- El modelo Holt-Winters fue el más recurrente, pero se comprobó que modelos como ElasticNet y XGBoost también ofrecen excelentes resultados en ciertos casos.
- La arquitectura construida es **escalable y transferible** a otras categorías de producto o entornos de demanda.
- Se recomienda **integrar este pipeline al proceso semanal de pronóstico de la empresa**, y en fases futuras evaluar el uso de modelos más complejos como Prophet, Croston y redes LSTM para capturar demanda errática o altamente dependiente de factores externos.
- Reducción en la pérdida de ingresos por ventas de alrededor del 87%.
- Reducción del 73% del riesgo de dar de baja inventario.

REFERENCIAS

- [1] Taylor, S.J., Letham, B. "Forecasting at scale. The American Statistician.", 2018
- [2] Kamble, S.S., Gunasekaran, A., Gawankar, S.A. "Big data analytics for sustainable agricultural supply chains: A review and research framework", 2019
- [3] Kaur, J., Singh, R. "Machine Learning Applications in Perishable Goods Supply Chain", 2022
- [4] Jaimes Campos, D. L., & López Zúñiga, E. "Modelo de forecast para predecir la demanda semanal de alimentos y bebidas", Universidad de los Andes, 2021
- [5] C. F. Chien, H. Y. Wang, Y. C. Lin, and C. Y. Chou, "A hybrid LSTM-based demand forecasting model for perishable food products," *Journal of Food Engineering*, vol. 316, p. 110875, 2022
- [6] Chopra, S., Meindl, P. (2020). *Supply Chain Management: Strategy, Planning, and Operation*. Pearson.
- [7] A. A. Syntetos, J. E. Boylan, and J. D. Croston, "On the categorization of demand patterns," *Journal of the Operational Research Society*, vol. 56, no. 5, pp. 495–503, 2005, doi: 10.1057/palgrave.jors.2601841.
- [8] R. J. Hyndman, "A note on the categorization of demand patterns," *Foresight: The International Journal of Applied Forecasting*, no. 10, pp. 5–7, 2008.
- [9] V. Varghese and M. Rossetti, "A classification approach for selecting forecasting techniques for intermittent demand," *Proceedings of the 2008 Winter Simulation Conference*, 2008.
- [10] J. D. Croston, "Forecasting and stock control for intermittent demands," *Operational Research Quarterly*, vol. 23, no. 3, pp. 289–303, 1972, doi: 10.1057/jors.1972.41.
- [11] S. D. Prestwich, S. A. Tarim, R. Rossi, and B. Hnich, "Forecasting intermittent demand by hyperbolic-exponential smoothing," *International Journal of Forecasting*, vol. 30, no. 4, pp. 928–933, 2013, doi: 10.1016/j.ijforecast.2013.01.004.
- [12] A. C. Turkmen, S. D. Prestwich, and R. Rossi, "Intermittent demand forecasting with renewal processes," *International Journal of Forecasting*, vol. 36, no. 2, pp. 669–686, 2020, doi: 10.1016/j.ijforecast.2019.10.003.
- [13] R. J. Hyndman and A. B. Koehler, "Another look at measures of forecast accuracy," *International Journal of Forecasting*, vol. 22, no. 4, pp. 679–688, 2006, doi: 10.1016/j.ijforecast.2006.03.001.
- [14] S. D. Prestwich, R. Rossi, and S. A. Tarim, "Mean-based error measures for intermittent demand forecasting," *Omega*, vol. 45, pp. 104–113, 2014, doi: 10.1016/j.omega.2013.12.005.
- [15] Frepple APS, "Demand classification: Why forecastability matters," 2024. [Online]. Available: <https://frepple.com/blog/demand-classification/>
- [16] A. C. Turkmen, S. D. Prestwich, and R. Rossi, "Intermittent demand forecasting with deep renewal processes," *Proceedings of the 2019 International Conference on Industrial Engineering and Operations Management*, 2019.