

Estrategia de Modelado de Demanda con Aprendizaje Automático

Contexto del Proyecto

Este proyecto tiene como objetivo desarrollar un modelo de predicción de la demanda para 26 productos lácteos con vida útil corta, a partir de series de tiempo diarias. El objetivo es predecir la demanda para los siguientes 7 días, con un enfoque en modelos de aprendizaje automático multivariados (regresión), evaluando su desempeño comparado con modelos clásicos.

Notebook principal (modular):

https://github.com/JhonattanReales21/innv_tec_1_icesi/blob/main/notebooks/ml_pipeline_p_sku.ipynb

Scripts (funciones):

https://github.com/JhonattanReales21/innv_tec_1_icesi/tree/main/src/utls_ml

Enfoque General

Se desarrollará un pipeline modular que incluye:

- Análisis exploratorio de datos
 - Generación de variables predictoras (feature engineering).
 - Optimización de hiper parámetros con Optuna (multiobjetivo), aplicando validación cruzada mediante ventana recursiva temporal.
 - Reentrenamiento y predicción final.
 - Visualización y reporte de resultados.
-

1. Exploratory Data analysis

- Se calculan métricas de interés por SKU como porcentaje de valores nulos, porcentaje de valores outliers, métricas de tendencia y variabilidad
 - Se grafica la descomposición STL por cada SKU, con periodo de 7, para identificar patrones generales y ganar conocimiento del comportamiento de cada sku.
-

2. Feature Engineering

a. Variables Temporales

- Día de la semana, día del mes, semana del mes
- Flags binarios para: fin de semana, primeros 5 días del mes (por posible abastecimiento), quincena (± 2 días), vacaciones escolares (julio y diciembre).

b. Lags y Promedios Móviles

- 14 lags diarios hacia atrás (Lag 1 a Lag 14).
- 3 lags del mismo día de la semana (por ejemplo, los últimos 3 martes).
- Promedios móviles excluyendo los días de cero pedidos:
 - De los últimos 2 días.
 - De los últimos 7 días.
 - Promedio semanal de la semana anterior (días -14 a -7).
 - Promedio de los mismos días de la semana en las 2 semanas anteriores.
 - Promedio de los mismos días de la semana en las 3 semanas anteriores

c. Descomposición STL

- Para cada serie, se extraen los componentes de tendencia y estacionalidad.
 - Para cada componente se generan 14 lags (Lag_Tendencia_1 a Lag_Tendencia_14 y Lag_Estacionalidad_1 a 14).
-

3. Modelos de Regresión a Evaluar

- XGBoost Regressor (Boosting)
 - Random Forest Regressor (Bagging)
 - Elastic Net (Modelo Lineal generalizado)
 - KNN Regressor (instance based model)
-

4. Protocolo de Validación: Ventana Recursiva

- Se realizan 3 cortes recursivos en la serie:
 - En cada corte, se entrena con el histórico disponible y se predicen los siguientes 7 días.

- Métricas calculadas en cada ventana:
 - **SMAPE de validación.**
 - **GAP = $ABS[SMAPE_{train} - SMAPE_{val}]$** , para evaluar sobreajuste.
 - Se almacenan los resultados en listas y se promedian al final.
-

5. Optimización de Hiperparámetros con Optuna

- Objetivo: Minimizar dos métricas simultáneas:
 - SMAPE promedio de las ventanas de validación.
 - GAP promedio.
 - Selección del mejor conjunto de hiper parámetros por modelo y por SKU.
-

6. Testing Final y Visualización

- Los últimos 7 días de cada serie se dejaron como datos de prueba.
 - Se reentrena el mejor modelo por SKU con todos los datos excepto esos 7 días.
 - Se evalúa sobre el test final usando MAE, RMSE, MAPE y SMAPE.
 - Se genera una gráfica por SKU mostrando:
 - Los últimos 35 días reales del entrenamiento.
 - El pronóstico generado por el modelo.
 - La demanda real en los 7 días de prueba.
-

Resultado Esperado

- Una estrategia reproducible, modular y explicable para pronóstico de demanda de productos perecederos.
- Comparación de varios modelos de ML en términos de precisión y generalización.
- Información accionable para mejorar la planeación de la producción y logística.

RESULTADOS:

- Mejor modelo evaluado por SKU y métricas sobre el test set (últimos 7 días de cada serie)

SKU	Modelo	RMSE	MAE	MAPE	SMAPE
SKU1	XGBRegressor	4804	3797	21,5	21,3
SKU10	ElasticNet	306	262	20,5	23,6
SKU11	ElasticNet	206	184	24,6	21,6
SKU12	ElasticNet	148	109	26,9	31,8
SKU13	RandomForestRegressor	238	190	43,6	38,4
SKU14	XGBRegressor	655	541	40,7	43,3
SKU15	XGBRegressor	180	142	13,2	13,2
SKU16	XGBRegressor	875	680	20,3	17,4
SKU17	ElasticNet	2399	2272	23,4	21,9
SKU18	KNeighborsRegressor	795	702	35,3	34,7
SKU19	KNeighborsRegressor	2335	2226	169,3	74,4
SKU2	XGBRegressor	1060	946	23,4	21,8
SKU20	ElasticNet	5850	4285	45,9	39,3
SKU21	XGBRegressor	1453	1201	55,7	40,6
SKU22	ElasticNet	895	752	34,8	27,7
SKU23	ElasticNet	781	621	15,1	15,4
SKU24	RandomForestRegressor	2251	2049	74,5	51,9
SKU25	ElasticNet	572	428	14,4	40,7
SKU26	ElasticNet	726	381	13,2	16,0
SKU3	ElasticNet	3131	2809	25,8	23,3
SKU4	ElasticNet	993	881	22,0	20,5
SKU5	ElasticNet	1804	1594	12,1	11,5
SKU6	ElasticNet	414	344	15,5	14,0
SKU7	XGBRegressor	4859	3257	87,6	39,2
SKU8	KNeighborsRegressor	1148	1014	153,9	143,1
SKU9	ElasticNet	976	688	80,3	68,1

















